HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

BỘ MÔN PHÂN TÍCH VÀ KHAI PHÁ DỮ LIỆU VĂN BẢN



BÁO CÁO BÀI TẬP LỚN I

Giảng viên : **TS. Nguyễn Thị Mai Trang**
Sinh viên : **Lã Quang Hải - B22DCKH037**
: **Nguyễn Bá Khánh Huy – B22DCKH051**
: **Nguyễn Văn Phúc – B22DCKH089**
: **Lương Minh Quý – B22DCKH099**
Nhóm lớp : **01**
Nhóm bài tập : **13**

Hà Nội – **2025**

Mục lục

I. Đề bài: 3
II. Cơ sở lý thuyết: 4
1. Phương pháp Bag of Words BoW: 4
2. Phương pháp TF-IDF: 4
3. Phương pháp Word Embeddings: 5
4. Phân loại Naïve Bayes: 6
5. Support Vector Machine SVM: 6
6. Xử lý vấn đề mất cân bằng dữ liệu: 6
7. Thư viện hỗ trợ: 6
III. Thực nghiệm và kết quả: 8
1. Code thực nghiệm: 8
2. Kết quả: 8
3. So sánh và nhận xét: 11
IV. Kết luận: 12
1. Kết quả đạt được: 12
2. Các hạn chế - Hướng cải thiện: 12
Tài liệu tham khảo: 13

Bảng đóng góp thành viên:

STT	Họ tên	Mã sinh viên	Công việc	Mức độ đóng góp
1	Lã Quang Hải	B22DCKH037	Xử lý mất cân bằng dữ liệu So sánh mô hình Viết báo cáo	25%
2	Nguyễn Bá Khánh Huy	B22DCKH051	Crawl dữ liệu Đánh giá mô hình	25%
3	Nguyễn Văn Phúc	B22DCKH089	Tiền xử lý dữ liệu Huấn luyện mô hình	25%
4	Lương Minh Quý	B22DCKH099	Crawl dữ liệu Tiền xử lý dữ liệu	25%

I. Đề bài:

Xây dựng hệ thống phân loại cảm xúc review sản phẩm trên sàn thương mại điện tử Lazada. Nhãn phân loại là nhãn **tích cực** – quy ước là 1, nhãn **trung tính** – quy ước là 0 và nhãn **tiêu cực** – quy ước là -1.
Các bước thực hiện bao gồm:
1. Thu thập dữ liệu: Gán nhãn reviews theo số sao kèm theo và hiệu chỉnh thủ công.
2. Tiền xử lý dữ liệu
3. Trích chọn đặc trưng: Thử nghiệm với 3 phương pháp: **BoW**, **TF-IDF** và **Word Embeddings**
4. Xây dựng và huấn luyện mô hình: Sử dụng 2 thuật toán phân loại: **Naïve Bayes** và **SVM**
5. Đánh giá mô hình, so sánh hiệu suất giữa các phương pháp

II. Cơ sở lý thuyết:

1. Phương pháp Bag of Words BoW:

- **Bag of Words** (BoW) là một kỹ thuật biểu diễn văn bản (chứ không chỉ là trích xuất tính năng) được sử dụng trong xử lý ngôn ngữ tự nhiên (NLP) và học máy. Nó biểu diễn một đoạn văn bản (như một câu, một đoạn, hoặc một tài liệu) như một tập hợp các từ và sự xuất hiện của chúng.

- Ý tưởng: Biểu diễn văn bản như một "túi" các từ, bỏ qua ngữ pháp và thứ tự từ, chỉ quan tâm đến tần suất xuất hiện của mỗi từ.

- **Cách hoạt động:**
    - Tạo một từ điển (vocabulary) chứa tất cả các từ duy nhất từ toàn bộ tập dữ liệu.
    - Mỗi văn bản được biểu diễn dưới dạng một véc-tơ có kích thước bằng kích thước từ điển.
    - Giá trị tại mỗi vị trí trong véc-tơ là số lần xuất hiện của từ tương ứng trong từ điển.

- Ưu điểm:
    - Đơn giản, hiệu quả, dễ triển khai.
    - Hiệu quả với các tập dữ liệu lớn.

- **Nhược điểm:**
    - Mất thông tin ngữ cảnh
    - Vấn đề từ hiếm (Sparsity)
    - Vấn đề từ mới (Out-of-vocabulary OOV)
    - Không nắm bắt được mối quan hệ ngữ nghĩa.

2. Phương pháp TF-IDF:

- **TF-IDF** (Term Frequency – Inverse Document Frequency) là một phương pháp thống kê nhằm đánh giá mức độ quan trọng của 1 từ đối với 1 tài liệu trong một tập hợp tài liệu.

- **Ý tưởng:** Một từ quan trọng là từ xuất hiện nhiều trong 1 tài liệu cụ thể (TF cao) nhưng lại ít xuất hiện trong các tài liệu khác (IDF cao).

- **Cách hoạt động:**
    - TF(t,d): tần suất xuất hiện của từ t trong tài liệu d.
    - IDF(t,D): Mức độ hiếm của từ t trong tập tài liệu D.
    - Thường người ta dùng công thức sau để làm mượt IDF:

$$IDF(t, D) = \log\left(\frac{1 + N}{1 + DF(t)}\right) + 1$$

- Ngoài ra, thư viện scikit-learn thực hiện thêm công thức chuẩn hóa cho từng tài liệu sao cho vector của mỗi tài liệu có chuẩn bằng 1:

$$\hat{v}_d = \frac{v_d}{\sqrt{\sum_i v_{d,i}^2}}$$

- Ưu điểm:

- Phản ánh tốt hơn mức độ quan trọng của từ so với BoW.
- Giảm ảnh hưởng của các từ phổ biến.
- Dễ hiểu và dễ tính toán.

- Nhược điểm:

- Vấn đề từ hiếm (sparsity).
- Không nắm bắt được mối quan hệ ngữ nghĩa.
- Không xử lý tốt từ đồng nghĩa, đa nghĩa.
- Không quan tâm đến thứ tự từ.

3. Phương pháp Word Embeddings:

- **Word Embeddings** biểu diễn từ dưới dạng các véc-tơ số thực dày đặc (dense vectors) trong không gian nhiều chiều.
- **Mục tiêu:** Nắm bắt được mối quan hệ ngữ nghĩa và ngữ pháp giữa các từ. Các từ có ý nghĩa tương đồng sẽ có véc-tơ gần nhau trong không gian.
- **Khắc phục** được các nhược điểm:
  - **Xử lý ngữ nghĩa:** Các từ có ý nghĩa tương tự sẽ có véc-tơ gần nhau, giúp mô hình hiểu được mối quan hệ.
  - **Biểu diễn dày đặc:** Giảm kích thước véc-tơ, hiệu quả hơn cho các mô hình học sâu.
  - **Giảm chiều:** Thay vì véc-tơ hàng trăm nghìn chiều (BoW), Word Embeddings thường chỉ vài trăm chiều.
  - **Xử lý OOV tốt hơn:** Có thể ước lượng véc-tơ cho từ mới dựa trên ngữ cảnh hoặc các thành phần của từ.l;

423

- Trong thực nghiệm, nhóm em sử dụng pretrained model PhoBERT (do VinAI phát triển) để trích chọn đặc trưng ngữ nghĩa cho văn bản tiếng Việt, kết hợp với thuật toán SVM. - Nhóm **không** áp dụng Word Embedding với Naïve Bayes vì giả định độc lập

  giữa các đặc trưng của Naïve Bayes không phù hợp với cách biểu diễn ngữ nghĩa liên tục và có quan hệ phụ thuộc trong Word Embedding.

4. Phân loại Naïve Bayes:

- **Naïve Bayes** là một thuật toán ngây thơ phân loại dựa trên Định lý Bayes, với giả định "ngây thơ" rằng các đặc trưng là độc lập với nhau.
- **Cách hoạt động:** Tính xác suất:

$$P(y|x1,x2,...,xn) \propto P(y).\ P(x1|y).\ P(x2|y)\ ...P(xn|y)$$

Trong đó: y là nhãn của lớp; x1,x2,…,xn là các đặc trưng của tài liệu.
Sau đó, chọn lớp có xác xuất cao nhất.
- Trong thực nghiệm, nhóm em sử dụng biến thể MultinomialNB, phù hợp với BoW, TF_IDF:
    - **MultinomialNB** giả định rằng các từ trong văn bản được sinh ra độc lập từ một **phân phối đa thức (multinomial distribution)**, điều kiện trên lớp y.

5. Support Vector Machine SVM:

- **SVM** là một thuật toán học có giám sát mạnh mẽ được sử dụng để phân loại và hồi quy.
- **Nguyên tắc cốt lõi:** Tìm một siêu mặt phẳng (hyperplane) tối ưu nhất để phân tách các lớp dữ liệu.
- Trong thực nghiệm, nhóm em sử dụng biến thể **LinearSVC,** chuyên giải quyết bài toán phân loại tuyến tính, phù hợp cho bài toán NLP với BoW, TF-IDF hoặc Word Embeddings.

6. Xử lý vấn đề mất cân bằng dữ liệu:

Sau tiền xử lý, dữ liệu bị mất cân bằng nghiêm trọng: trong tổng số 8.355 reviews thì có 7.553 nhãn **1** (đa số), trong khi nhãn **0** chỉ có 393 và nhãn **-1** chỉ có 409.

- Naïve Bayes: áp dụng kết hợp **undersampling** cho nhãn 1 (giảm bớt dữ liệu đa số) và **oversampling** cho nhãn -1 (tăng dữ liệu thiểu số) để tạo tập huấn luyện cân bằng hơn.

- SVM: sử dụng tham số class_weight="balanced". Khi đó, SVM sẽ **tự động gán trọng số ngược tỉ lệ với tần suất nhãn**: nhãn xuất hiện ít sẽ được gán trọng số cao hơn, giúp mô hình không thiên lệch về phía nhãn đa số.

Sau nhiều lần thực nghiệm, nhóm thu được kết quả tốt nhất với số lượng mẫu như sau:

- Naive Bayes: **hybrid sampling:** undersampling nhãn 1 xuống 2000 mẫu, oversampling nhãn -1 và nhãn 0 lên 1000 mẫu.
- SVM: không có sự khác biệt lớn về kết quả khi thay đổi tỷ lệ giữa các nhãn. Nhóm quyết định lấy toàn bộ mẫu.

7. Thư viện hỗ trợ:

- Thư viện langdetect: dùng để nhận diện ngôn ngữ của văn bản.

- Trong thực nghiệm, nhóm ứng dụng thư viện này để lọc và xử lý những reviews là tiếng Việt, giúp vocab không bị gây nhiễu.

- Thư viện scikit-learn (sklearn): là một thư viện **machine learning** nổi tiếng và phổ biến nhất hiện nay trong Python.
    - Trong thực nghiệm, sklearn cung cấp công cụ giúp đỡ trong việc: tiền xử lý dữ liệu, huấn luyện và đánh giá mô hình.

III. Thực nghiệm và kết quả:

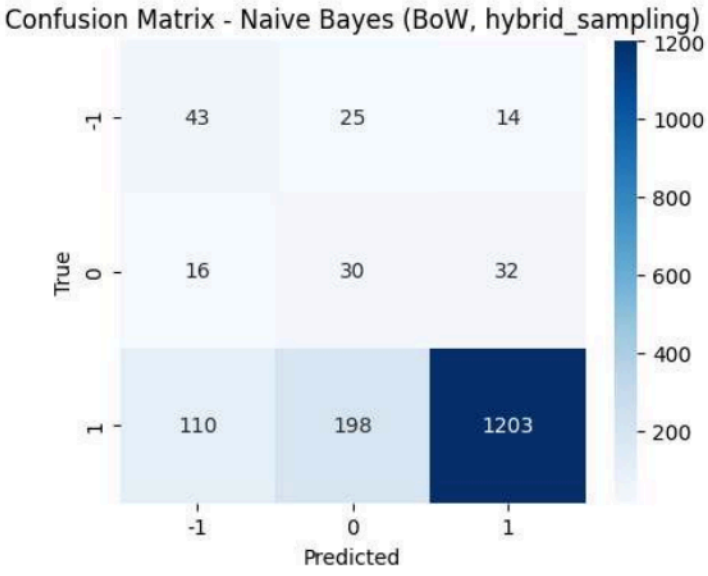
1. Code thực nghiệm:

Code thu thập dữ liệu: https://github.com/LMQ-Ptit/Crawdata.git
Code xử lý dữ liệu, huấn luyện và đánh giá mô hình:
https://www.kaggle.com/code/hainaonao/btl01

2. Kết quả:

===== Naive Bayes (BoW, hybrid_sampling) =====

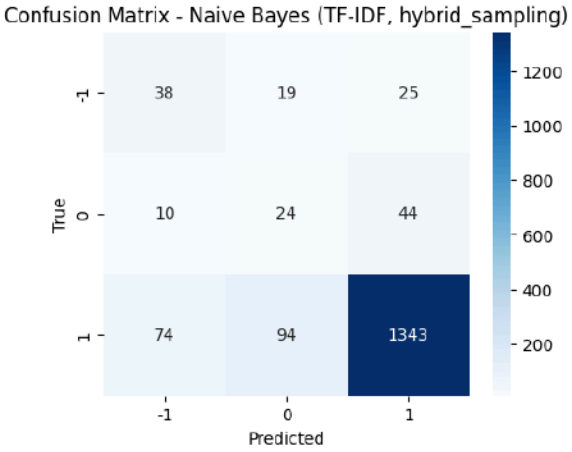
	precision	recall	f1-score	support
-1	0.254	0.524	0.343	82
0	0.119	0.385	0.181	78
1	0.963	0.796	0.872	1511
accuracy			0.764	1671
macro avg	0.445	0.568	0.465	1671
weighted avg	0.889	0.764	0.814	1671



```
===== Naive Bayes (TF-IDF, hybrid_sampling) =====
              precision    recall  f1-score   support

          -1      0.311     0.463     0.373        82
           0      0.175     0.308     0.223        78
           1      0.951     0.889     0.919      1511

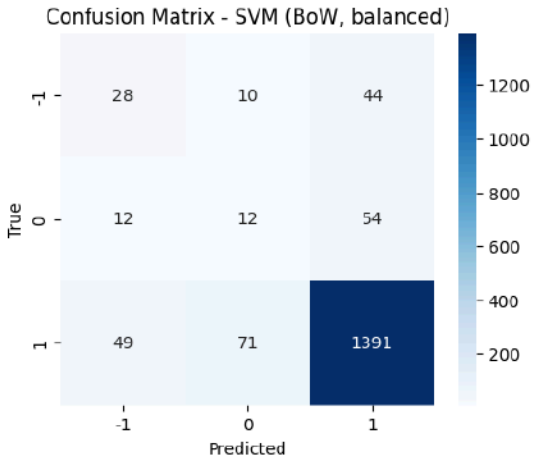
    accuracy                          0.841      1671
   macro avg      0.479     0.553     0.505      1671
weighted avg      0.884     0.841     0.860      1671
```




```
===== SVM (BoW, balanced) =====
              precision    recall  f1-score   support

          -1      0.315     0.341     0.327        82
           0      0.129     0.154     0.140        78
           1      0.934     0.921     0.927      1511

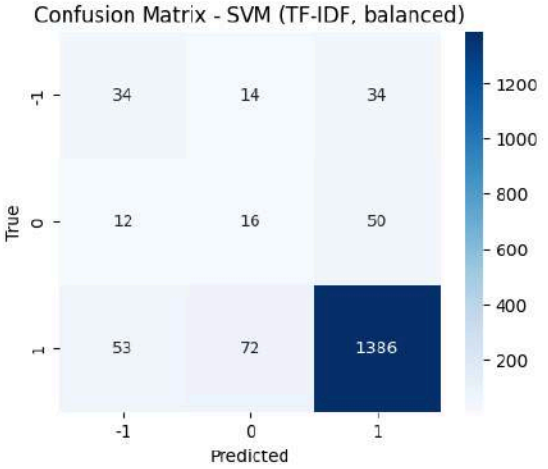
    accuracy                          0.856      1671
   macro avg      0.459     0.472     0.465      1671
weighted avg      0.866     0.856     0.861      1671
```



```
===== SVM (TF-IDF, balanced) =====
              precision    recall  f1-score   support

          -1      0.343     0.415     0.376        82
           0      0.157     0.205     0.178        78
           1      0.943     0.917     0.930      1511

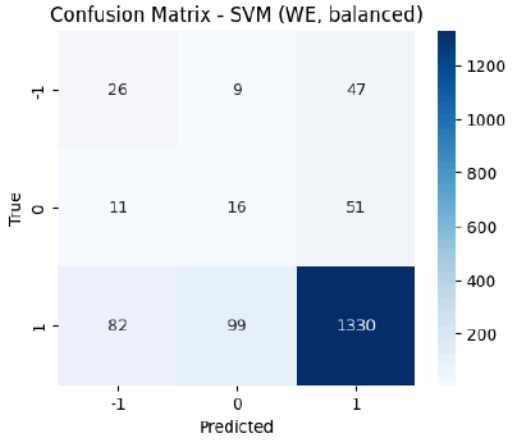
    accuracy                          0.859      1671
   macro avg      0.481     0.512     0.494      1671
weighted avg      0.877     0.859     0.868      1671
```




```
===== SVM (WE, balanced) =====
              precision    recall  f1-score   support

          -1      0.218     0.317     0.259        82
           0      0.129     0.205     0.158        78
           1      0.931     0.880     0.905      1511

    accuracy                          0.821      1671
   macro avg      0.426     0.467     0.441      1671
weighted avg      0.859     0.821     0.838      1671
```



3. So sánh và nhận xét:

Model	Accuracy	Macro-F1	Weighted-F1	Precision	Recall
Naive Bayes (BoW, hybrid_sampling)	0.763615	0.465212	0.813544	0.445395	**0.568389**
Naive Bayes (TF-IDF, hybrid_sampling)	0.840814	**0.504908**	0.859635	0.479264	0.553307
SVM (BoW, balanced)	0.856373	0.465057	0.861162	0.459274	0.471964
SVM (TF-IDF, balanced)	**0.859366**	0.494453	**0.867586**	**0.481051**	0.512345
SVM (WE, balanced)	0.821065	0.440731	0.838498	0.426297	0.467471

- Về phương pháp **trích chọn đặc trưng:** TF-IDF vượt trội so với BoW ở cả 2 thuật toán.
- Về **thuật toán:** Thuật toán **SVM** đang cho kết quả tốt hơn ở cả 2 phương pháp trích chọn đặc trưng.
- SVM (TF-IDF, balanced) đang cho kết quả tốt nhất ở nhiều chỉ số, nhưng Naive Bayes (TF-IDF, hybrid_sampling) lại thể hiện tốt hơn trong việc xử lý **mất cân bằng dữ liệu**.
- Nhìn chung, precision và recall đều chưa quá cao -> Mô hình vẫn **chưa phân biệt tốt** giữa các ranh giới. Nguyên nhân chủ yếu do việc **mất cân bằng dữ liệu** vẫn chưa được xử lý tốt.

IV. Kết luận:

1. Kết quả đạt được:

Trong quá trình thực nghiệm, nhóm đã triển khai hai kỹ thuật trích chọn đặc trưng phổ biến là **Bag-of-Words (BoW)**, **TF-IDF (Term Frequency - Inverse Document Frequency)** và **Word Embeddings**. Trên cơ sở đó, hai mô hình được áp dụng là **Naïve Bayes (NB)** và **Support Vector Machine (SVM)**.

Kết quả thực nghiệm cho thấy:

- BoW, TF-IDF và **Word Embeddings:**

- BoW cho phép mô hình hóa văn bản thành các vector đơn giản, dễ triển khai, nhanh trong tính toán.
- TF-IDF đã khắc phục được một phần hạn chế của BoW khi giảm trọng số cho các từ xuất hiện quá nhiều, làm nổi bật những từ mang tính phân biệt cao. Điều này giúp cải thiện đáng kể kết quả của cả NB và SVM.
- Word Embeddings trong trường hợp này chưa phát huy được ưu thế, có thể do cách trích xuất embedding đơn giản.

- Naïve Bayes:

- Kết quả Macro-F1 và Weighted-F1 đạt mức khá, đặc biệt khi kết hợp với TF-IDF và kỹ thuật resampling (undersampling + oversampling).

- SVM:

- Khi áp dụng class_weight="balanced", SVM đã giảm thiểu được phần nào sự thiên lệch về nhãn đa số.
- Khi kết hợp với TF-IDF, SVM cho kết quả tốt nhất trên nhiều chỉ số.

Tổng thể, việc áp dụng BoW/TF-IDF/WE kết hợp với NB và SVM đã chứng minh tính khả thi, giúp mô hình đạt độ chính xác (Accuracy) khá cao trên tập test. Tuy nhiên, các chỉ số **Precision** và **Recall** cho nhãn thiểu số (0 và -1) còn thấp, phản ánh những hạn chế quan trọng cần cải thiện.

2. Các hạn chế - Hướng cải thiện:

Mất cân bằng dữ liệu: Trong 8355 review, nhãn tích cực (1) chiếm tới 7553, trong khi nhãn trung tính (0) chỉ có 393, nhãn tiêu cực (-1) chỉ có 409. Tỉ lệ này gây mất cân bằng nghiêm trọng, khiến mô hình thiên lệch dự đoán về nhãn 1.

=> Giải quyết mất cân bằng bằng hybrid sampling và augmentation.

Hạn chế về biểu diễn ngữ nghĩa:

- BoW và TF-IDF chỉ xem xét tần suất từ, hoàn toàn bỏ qua ngữ cảnh, quan hệ cú pháp, trật tự từ.

- Với tiếng Việt, nhiều trường hợp từ ghép, từ láy, hoặc phủ định (vd: “không tệ”, “chưa tốt”) rất khó được mô hình phân biệt.

=> Chuyển từ BoW/TF-IDF sang embedding hoặc contextual embedding để tận dụng ngữ nghĩa.

Hạn chế về Word Embeddings:

- Với cách lấy trung bình embedding, mô hình làm mất thông tin về vị trí và quan hệ giữa các từ.
- Embedding tĩnh hoặc pooling đơn giản chưa tận dụng hết ngữ cảnh động, đặc biệt trong tiếng Việt có nhiều từ ghép, phủ định, từ láy.

=> Cải thiện bằng cách fine-tune PhoBERT, thử các cách pooling khác (CLS, max, attention), kết hợp nhiều tầng embedding, hoặc dùng mô hình ngữ cảnh mới (XLM-R, ViT5).

Khả năng phân loại còn hạn chế:

- Precision và Recall thấp ở nhãn -1 và 0 cho thấy mô hình còn nhầm lẫn nhiều giữa các lớp ít dữ liệu.
- SVM chưa được tối ưu tham số đầy đủ, và Naïve Bayes vốn có giả định độc lập giữa các đặc trưng, điều này không đúng với văn bản.

=> Sử dụng mô hình mạnh hơn, đặc biệt là các mô hình Transformers.

Tài liệu tham khảo:

[1] Bộ slide Phân tích và khai phá dữ liệu văn bản.